

MÔ TẢ CÁC VẤN ĐỀ VỀ DỮ LIỆU CẦN ĐƯỢC XỬ LÝ BẰNG PYTHON

1. Thiếu dữ liệu (Missing values)

- Thiếu dữ liệu cỡ cột Postal Code và thiếu 41296 dòng

```
print(df.isnull().sum()) #số lượng giá trị thiếu trên mỗi cột
```

Row ID	0
Order ID	0
Order Date	0
Ship Date	0
Ship Mode	0
Customer ID	0
Customer Name	0
Segment	0
City	0
State	0
Country	0
Postal Code	41296
Market	0
Region	0
Product ID	0
Category	0
Sub-Category	0
Product Name	0
Sales	0
Quantity	0
Discount	0
Profit	0
Shipping Cost	0
Order Priority	0

dtype: int64

2. Sai kiểu dữ liệu (Data type mismatch)

- Cột ngày (Order Date, Ship Date) → hiện đang ở dạng object (text), cần chuyển về datetime.

```
#kiểm tra kiểu dữ liệu
print(df.dtypes)
```

Row ID	int64
Order ID	object
Order Date	object
Ship Date	object
Ship Mode	object
Customer ID	object
Customer Name	object
Segment	object
City	object
State	object
Country	object
Postal Code	float64
Market	object
Region	object
Product ID	object
Category	object
Sub-Category	object
Product Name	object
Sales	float64
Quantity	int64
Discount	float64
Profit	float64
Shipping Cost	float64
Order Priority	object

dtype: object

- Cột số (Sales, Profit, Postal Code) có ký tự chữ ?

3. Trùng dữ liệu (Duplicates)

- Không có dòng dữ liệu trùng lặp

```
print("Số dòng trùng lặp:", df.duplicated().sum())
```

[17] ✓ 0.0s Python

... Số dòng trùng lặp: 0

Generate + Code + Markdown

4. Giá trị bất thường (Outliers)

- Cột Profit có 12544 giá trị < 0

```
# Danh sách các cột số cần kiểm tra
numeric_cols = ["Sales", "Profit", "Quantity", "Discount", "Shipping Cost"]

for col in numeric_cols:
    negative_values = df[df[col] < 0]
    if not negative_values.empty:
        print(f"Cột {col} có {len(negative_values)} giá trị < 0")
    else:
        print(f"Cột {col} không có giá trị < 0")
```

[17] ✓ 0.0s Python

Cột Sales không có giá trị < 0
Cột Profit có 12544 giá trị < 0
Cột Quantity không có giá trị < 0
Cột Discount không có giá trị < 0
Cột Shipping Cost không có giá trị < 0

5. Dữ liệu có nhất quán hay không

- Không có sự khác biệt viết hoa/thường ở các cột Customer Name, City, State, Country

```
# Các cột cần kiểm tra
text_columns = ["Customer Name", "City", "State", "Country"]

for col in text_columns:
    unique_values = df[col].dropna().unique()

    # So sánh khi chuyển sang upper (hoặc lower)
    unique_upper_count = len(set([str(v).upper() for v in unique_values]))
    unique_original_count = len(unique_values)

    has_case_issue = unique_upper_count != unique_original_count

    print(f"{col}:")
    print(f"  Số giá trị duy nhất gốc: {unique_original_count}")
    print(f"  Sau khi chuẩn hóa (UPPER): {unique_upper_count}")
    print(f"  Có khác biệt viết hoa/thường không? {has_case_issue}\n")
```

[44] Python

... Customer Name:
Số giá trị duy nhất gốc: 795
Sau khi chuẩn hóa (UPPER): 795
Có khác biệt viết hoa/thường không? False

City:
Số giá trị duy nhất gốc: 3636
Sau khi chuẩn hóa (UPPER): 3636
Có khác biệt viết hoa/thường không? False

```
State:
Số giá trị duy nhất gốc: 1094
Sau khi chuẩn hóa (UPPER): 1094
Có khác biệt viết hoa/thường không? False

Country:
Số giá trị duy nhất gốc: 147
Sau khi chuẩn hóa (UPPER): 147
Có khác biệt viết hoa/thường không? False
```

- Tên quốc gia không bị nhập khác nhau cho cùng một nơi.

```
#kiểm tra dữ liệu có đang bị nhập khác nhau cho cùng một giá trị hay không
print(df["Country"].unique()) #in ra danh sách các quốc gia khác nhau có trong cột "Country"
```

```
['United States' 'Australia' 'Germany' 'Senegal' 'New Zealand'
'Afghanistan' 'Saudi Arabia' 'Brazil' 'China' 'France' 'Italy' 'Tanzania'
'Poland' 'United Kingdom' 'Mexico' 'El Salvador' 'Taiwan' 'India'
'Dominican Republic' 'Democratic Republic of the Congo' 'Indonesia'
'Uruguay' 'Iran' 'Mozambique' 'Bangladesh' 'Spain' 'Ukraine' 'Nicaragua'
'Morocco' 'Canada' 'Philippines' 'Austria' 'Colombia' 'Netherlands'
'Malaysia' 'Ecuador' 'Thailand' 'Somalia' 'Guatemala' 'Belarus'
'Cambodia' 'South Africa' 'Japan' 'Russia' 'Egypt' 'Azerbaijan'
'Lithuania' 'Argentina' 'Lesotho' 'Vietnam' 'Cuba' 'Romania' 'Turkey'
'Cameroon' 'Hungary' 'Singapore' 'Angola' 'Belgium' 'Pakistan' 'Finland'
'Ghana' 'Zambia' 'Iraq' 'Liberia' 'Georgia' 'Switzerland' 'Albania'
'Chad' 'Montenegro' 'Namibia' 'Portugal' 'Madagascar' 'Sweden'
'Myanmar (Burma)' 'Jamaica' 'Qatar' 'Republic of the Congo' 'Norway'
'Algeria' 'South Korea' 'Nigeria' 'Estonia' 'Cote d'Ivoire' 'Honduras'
'Paraguay' 'Czech Republic' 'Central African Republic' 'Benin' 'Bolivia'
'Chile' 'Martinique' 'Syria' 'Lebanon' 'Kenya' 'Mali' 'Libya' 'Venezuela'
'Trinidad and Tobago' 'Ireland' 'Bulgaria' 'Panama' 'Israel' 'Haiti'
'Barbados' 'Slovenia' 'Togo' 'Mauritania' 'Guinea' 'Rwanda' 'Denmark'
'Niger' 'Papua New Guinea' 'Mongolia' 'Sudan' 'Peru' 'Sierra Leone'
'Bosnia and Herzegovina' 'Guinea-Bissau' 'Djibouti' 'Tunisia' 'Croatia'
'Hong Kong' 'Nepal' 'Guadeloupe' 'Kyrgyzstan' 'Zimbabwe' 'Uzbekistan'
'South Sudan' 'Gabon' 'Bahrain' 'Yemen' 'Jordan' 'United Arab Emirates'
'Moldova' 'Swaziland' 'Turkmenistan' 'Kazakhstan' 'Ethiopia' 'Uganda'
'Slovakia' 'Sri Lanka' 'Tajikistan' 'Burundi' 'Macedonia' 'Eritrea'
'Equatorial Guinea' 'Armenia']
```

6. Logic Thời Gian

- Logic thời gian hợp lý : Ship Date > Order Date

```
#chuyển kiểu dữ liệu của Order Date và Ship Date
df["Order Date"] = pd.to_datetime(df["Order Date"], format="%d/%m/%Y", errors="coerce")
df["Ship Date"] = pd.to_datetime(df["Ship Date"], format="%d/%m/%Y", errors="coerce")
```

[34] ✓ 0.0s

```
#kiểm tra logic thời gian giữa Order Date và Ship Date
if "Order Date" in df.columns and "Ship Date" in df.columns:
    invalid_dates = df[df["Ship Date"] < df["Order Date"]]
    print("Số bản ghi Ship Date < Order Date:", len(invalid_dates))
```

[36] ✓ 0.0s

... Số bản ghi Ship Date < Order Date: 0

Kết luận:

- Thiếu dữ liệu ở cột Postal Code và thiếu 41296 dòng

- Cột ngày (Order Date, Ship Date) → hiện đang ở dạng object (text), cần chuyển về datetime.
- Cột Profit có 12544 giá trị bất thường < 0